

Clasificación Bayesiana Estimación paramétrica de densidades desconocidas

FaMAF

2019

Hipótesis sobre datos en un entorno Bayesiano

Podemos diseñar un estimador Bayesiano óptimo si sabemos:

- $p(\omega_i)$ probabilidades a priori
- $p(\mathbf{x}|\omega_i)$ densidades condicionales a la clase.

Desafortunadamente, raramente se tiene toda esta información completa !!

Podemos diseñar un clasificador Bayesiano usando una muestra de entrenamiento D para estimar parámetros no especificados.

- Estimación a priori no es un problema.
- Muestras son a menudo muy chicas para estimación condicional por clase, sobre todo si el espacio de características es de dimensión muy alta.

Diseño



- Para simplificar el problema de diseño del clasificador, se asumen formas paramétricas de las densidades $p(\mathbf{x}|\omega_i, \theta_i)$, donde θ_i son vectores de parámetros desconocidos que cambian por clase.
- Se asume también que se sabe el número de parámetros a estimar, es decir, la dimensión del vector θ por clase.
- Las técnicas que se discutirán son
 - ▶ Máxima verosimilitud (MV)
 - ▶ Estimación Bayesiana (EB)

Ejemplo

Supongamos tener k clases diferentes para clasificar.

- Si $p(\mathbf{x}|\omega_i)$ es una densidad normal, entonces se puede modelar estimando los parámetros media μ_i y matriz de covarianza Σ_i a partir de datos etiquetados D_i .
- La densidad $p(\mathbf{x}|\omega_i)$ se puede modelar adecuadamente con una única distribución normal.
- El clasificador decide por la clase i -ésima si $p(\omega_i|\mathbf{x}, \hat{\mu}_i, \hat{\Sigma}_i)$ es máxima.

Ejemplo



Si la distribución de las clases no siguen una distribución normal (izquierda), entonces la densidad $p(\mathbf{x}|\omega_i)$ puede sub-estimarse cuando se modela con una sola densidad Gaussiana, generando un clasificador con baja capacidad de generalización (derecha).

Ejemplo

Solución:

- Combinar varias densidades normales para mejorar la estimación de la función de verosimilitud $p(\mathbf{x}|\omega_i)$ de acuerdo a la distribución real de los datos:

$$p(\mathbf{x}|\omega_i) = \alpha_1 \mathcal{N}(\boldsymbol{\mu}_{i1}, \boldsymbol{\Sigma}_{i1}) + \dots + \alpha_m \mathcal{N}(\boldsymbol{\mu}_{im}, \boldsymbol{\Sigma}_{im}) \quad (1)$$

- Problemas:

- ▶ ¿Cómo determinar los parámetros $\boldsymbol{\mu}_{ik}$, $\boldsymbol{\Sigma}_{ik}$ y α_k
- ▶ ¿Cuál es el número óptimo m^* de densidades normales?

Estimación de Máxima Verosimilitud

- Estimar el vector de parámetros desconocidos θ de la distribución $p(\mathbf{x}|\theta)$ a partir del conjunto de datos $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$
- Función de verosimilitud de con respecto de \mathbf{X} :

$$p(\mathbf{X}|\theta) = p(\mathbf{x}_1, \dots, \mathbf{x}_n|\theta) = \prod_{i=1}^n p(\mathbf{x}_i|\theta) \quad (2)$$

- La estimación de máxima verosimilitud (MV) es un método para encontrar los parámetros que mejor ajusten la función $p(\mathbf{x}|\theta)$.

Estimación de Máxima Verosimilitud


- Suponga que se quiere estimar un sólo parámetro θ , el estimador $\hat{\theta}$ de máxima verosimilitud es el valor de θ que maximiza $p(\mathbf{x}|\theta)$, esto es

$$\hat{\theta} = \arg \max_{\theta} \prod_{i=1}^n p(\mathbf{x}_i | \theta) \quad (3)$$


- Ese estadístico también realiza el máximo de la función de log-verosimilitud $\mathcal{L}(\theta) \equiv \ln p(\mathbf{x}|\theta)$, esto es

$$\hat{\theta} = \arg \max_{\theta} \sum_{i=1}^n \ln p(\mathbf{x}_i | \theta) \quad (4)$$

Estimación de Máxima Verosimilitud



(a)



(b)

(a) Puntos en una dimensión tomados de una distribución Gaussiana con varianza específica y media desconocida. Se muestran cuatro de un número infinito de distribuciones fuente candidatas. (b) Verosimilitud (curva negra) y log-verosimilitud (curva roja) en función de la media. El valor que maximiza la verosimilitud es señalado con $\hat{\theta}$.

Estimación de Máxima Verosimilitud

Generalizando la verosimilitud como una función de los k parámetros desconocidos $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$; el estimador vectorial de máxima verosimilitud es el vector $\hat{\boldsymbol{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ que maximiza la $\mathcal{L}(\boldsymbol{\theta}) \equiv \ln p(\mathbf{x}|\boldsymbol{\theta})$

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} \sum_{i=1}^n \ln p(\mathbf{x}_i | \boldsymbol{\theta}) \quad (5)$$

En la mayoría de los casos, esto se reduce a resolver la ecuación

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}) = \sum_{i=1}^n \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{x}_i | \boldsymbol{\theta}) = \mathbf{0} \quad (6)$$

donde el operador gradiente es

$$\nabla_{\boldsymbol{\theta}} \equiv \left[\frac{\partial}{\partial \theta_1}, \dots, \frac{\partial}{\partial \theta_k} \right]^T \quad (7)$$


Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$

- Suponga que n muestras x_1, \dots, x_n fueron generadas a partir de una distribución normal univariada con media μ y varianza σ^2 .
- La función de log-verosimilitud de la normal unidimensional es


$$\mathcal{L}(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 \quad (8)$$

- Para estimar los parámetros μ y σ^2 por máxima verosimilitud se buscan los valores críticos de la $\mathcal{L}(\mu, \sigma^2)$

Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$



(a)



(b)

(a) Conjuntos de datos unidimensionales tomados aleatoriamente de una distribución Gaussiana $\mathcal{N}(10, 3)$). (b) Función de log-verosimilitud en cuyo máximo se encuentran los parámetros estimados $\hat{\theta}$: $\hat{\mu} = 9.7$, $\hat{\sigma}^2 = 3.1$

Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$

Aplicando el método de Máxima verosimilitud dado en (4) a la función de log verosimilitud en (8)

$$\begin{aligned}\frac{\partial \mathcal{L}(\mu, \sigma^2)}{\partial \mu} &= \sum_{k=1}^n (x_k - \mu) = 0 \\ \frac{\partial \mathcal{L}(\mu, \sigma^2)}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{k=1}^n (x_k - \mu)^2 = 0\end{aligned}\tag{9}$$

Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$

Reacomodando los términos en (9) se obtienen los estimadores de máxima verosimilitud para μ y σ^2

$$\begin{aligned}\hat{\mu} &= \frac{1}{n} \sum_{k=1}^n x_k \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2\end{aligned}\tag{10}$$

Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$

Sesgo de un estimador: diferencia entre el valor esperado de $\hat{\theta}$ y el valor real θ .

- El estimador MV para la media μ no está sesgado: $E(\hat{\mu}) = \mu$.
- El estimador MV para la varianza σ^2 es sesgado:

$$\mathbb{E} \left[\frac{1}{n} \sum_{k=1}^n (x_k - \mu)^2 \right] = \underbrace{\frac{n-1}{n} \sigma^2}_{\text{sesgo}} \neq \sigma^2 \quad (11)$$

- Varianza de la muestra sin sesgo:

$$S = \frac{1}{n-1} \sum_{k=1}^n (x_k - \hat{\mu})^2 \quad (12)$$

Estimación de Máxima Verosimilitud para la $\mathcal{N}(\mu, \sigma^2)$

En el caso más general, la función de log-verosimilitud de la normal multivariada es:

$$\mathcal{L}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}| \quad (13)$$

donde los estimadores MV para $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$ son

$$\begin{aligned}\hat{\boldsymbol{\mu}} &= \frac{1}{n} \sum_{k=1}^n \mathbf{x}_k \\ \hat{\boldsymbol{\Sigma}} &= \frac{1}{n-1} \sum_{k=1}^n (\mathbf{x}_k - \hat{\boldsymbol{\mu}}) (\mathbf{x}_k - \hat{\boldsymbol{\mu}})^T\end{aligned}\quad (14)$$

Estimacion Bayesiana

- Estimación de máxima verosimilitud supone θ un parámetro fijo.
- Estimación Bayesiana considera θ una variable aleatoria con densidad $p(\theta|\theta_0)$, con θ_0 parámetros conocidos.
- La muestra de entrenamiento permite cambiar el problema de etiquetar clases por el problema de estimar densidades.

Estimación Bayesiana

- Si tenemos k clases, queremos clasificar el dato x en la clase que produza el máximo valor de $p(\omega_i|x)$, $1 \leq i \leq k$.

$$p(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{\sum_{i=1}^k p(x|\omega_i)P(\omega_i)}$$

- Sabemos que $p(x|\omega_i)$ tiene un parámetro θ desconocido.
- Se tiene una muestra aleatoria D_i de la distribución $p(x|\omega_i)$.
- Lo mas cercano que podemos conocer es $p(x|\omega_i, D_i)$. Por lo cual la regla va a clasificar x en la clase i si ésta hace máxima a

$$p(\omega_i|x, D) = \frac{p(x|\omega_i, D_i)P(\omega_i)}{\sum_{i=1}^k p(x|\omega_i, D_i)P(\omega_i)}$$

Estimacion Bayesiana

- Sea θ una variable aleatoria con densidad $p(\theta)$ conocida. Para cada θ fijo, sea $p(x|\theta)$ una densidad conocida.
- Podemos encontrar $p(x|\omega_i, D_i)$ integrando la densidad conjunta $P(x, \theta|D)$ sobre θ .

$$p(x|\omega_i, D_i) = \int p(x, \theta|D)d\theta = \int p(x|\theta)p(\theta|D)d\theta$$

- Si $p(\theta|D)$ tiene un pico agudo en algun valor θ_e resulta $p(x|\omega_i, D) \sim p(x|\theta_e)$
- Si no es asi se promedia $p(x|\theta)$ sobre todos los valores de θ .

Estimacion Bayesiana

- La densidad a posteriori $p(\theta|D)$

$$\begin{aligned} p(\theta|D) &= \frac{p(D|\theta) \cdot p(\theta)}{\int p(D|\theta) \cdot p(\theta) d\theta} \\ &= \alpha \prod_{k=1}^n p(x_k|\theta) \cdot p(\theta) \end{aligned} \tag{15}$$

- $p(D|\theta) = \prod_{k=1}^n p(x_k|\theta)$ puede calcularse en forma recursiva.

Estimacion Bayesiana: Caso Normal univariado

- Sea $p(x|\theta_i)$ la densidad $\mathcal{N}(\mu_i, \sigma_i^2)$, donde μ_i es desconocido y σ_i^2 conocido, $1 \leq i \leq k$.
- Supongamos que $p(\mu_i) \sim \mathcal{N}(\mu_{0,i}, \sigma_{0,i}^2)$ con $\mu_{0,i}$ y $\sigma_{0,i}^2$ conocidos.
- Entonces

$$\begin{aligned} p(\mu_i | D_i) &= \frac{p(D_i | \mu_i) \cdot p(\mu_i)}{\int p(D_i | \mu_i) \cdot p(\mu_i) d\mu_i} \\ &= \alpha \prod_{k=1}^n p(x_k | \mu_i) \cdot p(\mu_i) \end{aligned} \tag{16}$$

- Reemplazando por las densidades supuestas queda

$$\begin{aligned} p(\mu_{0,i} | D_i) &\sim N(\mu_{i,n}, \sigma_{i,n}^2) \\ \mu_{i,n} &= \left(\frac{n\sigma_0^2}{n\sigma_{i,0}^2 + \sigma_i^2} \right) \bar{x}_n + \frac{\sigma_i^2}{n\sigma_{i,0}^2 + \sigma_i^2} \cdot \mu_{0,i} \\ \sigma_n^2 &= \frac{\sigma_{i,0}^2 \sigma_i^2}{n\sigma_{i,0}^2 + \sigma_i^2} \end{aligned} \tag{17}$$

Estimacion Bayesiana: Caso Normal univariado

- Usando la densidad $p(\mu_i | D_i)$ calculada, y la fórmula

$$p(x|\omega_i, D_i) = \int p(x|\mu) \cdot p(\mu|D)d\mu \quad (18)$$

se ve que $p(x|\omega_i, D_i)$ tiene distribución Normal

$$p(x|\omega_i, D_i) \sim N(\mu_{i,n}, \sigma_i^2 + \sigma_{i,n}^2) \quad (19)$$

- Junto a las probabilidades a priori $p(\omega_i)$ se tiene toda la información para diseñar el clasificador.

Estimacion Bayesiana Recursiva

- $D^n = \{x_1, \dots, x_n\}$ muestra de entrenamiento.
- La ecuación

$$p(D^n|\theta) = \prod_{k=1}^n p(x_k|\theta) \quad (20)$$

puede calcularse en forma recursiva

$$p(D^n|\theta) = p(x_n|\theta) p(D^{n-1}|\theta)$$

- Por lo tanto $p(\theta|D)$ tambien puede calcularse en forma recursiva, observando que antes de que se tenga ningun dato,

$$p(\theta|D^0) = p(\theta) \quad (21)$$

Estimacion Bayesiana Recursiva

- Cuando se observa el primer dato

$$p(\theta|D^1) \propto p(x_1|\theta)p(\theta) = p(x_1|\theta)p(\theta|D^0) \quad (22)$$

- Cuando se observa el segundo dato

$$p(\theta|D^2) \propto p(x_2|\theta)p(x_1|\theta)p(\theta) = p(x_2|\theta)p(D^1|\theta) \quad (23)$$

- En general

$$p(\theta|D^n) = \frac{p(x_n|\theta)p(\theta|D^{n-1})}{\int p(x_n|\theta)p(\theta|D^{n-1})d\theta} \quad (24)$$

Ejemplo Estimacion Bayesiana Recursiva

- Supongamos que las muestras provienen de una distribución uniforme

$$p(x|\theta) \sim U(0, \theta) = \begin{cases} 1/\theta & 0 \leq x \leq \theta \\ 0 & \text{afuera} \end{cases} \quad (25)$$

- Se supone un prior no informativo o flat

$$p(\theta) \sim U(0, 10) \quad (26)$$

- Datos seleccionados aleatoriamente de la distribución subyacente D={ 4,7,2,8}

Ejemplo Estimacion Bayesiana Recursiva

- Antes que se tenga ningún dato

$$p(\theta|D^0) = p(\theta) = U(0, 10) \quad (27)$$

- Cuando el primer dato $x_1 = 4$ se observa, olvidando la renormalización

$$p(\theta|D^1) \propto p(x|\theta)p(\theta|D^0) = \begin{cases} 1/\theta & 4 \leq \theta \leq 10 \\ 0 & \text{afuera} \end{cases} \quad (28)$$

- Cuando el siguiente dato $x_2 = 7$ se observa

$$p(\theta|D^2) \propto p(x|\theta)p(\theta|D^1) = \begin{cases} 1/\theta^2 & 7 \leq \theta \leq 10 \\ 0 & \text{afuera} \end{cases} \quad (29)$$

Ejemplo Estimacion Bayesiana Recursiva

- La forma general de la solución es

$$p(\theta|D^n) \propto 1/\theta^n \quad \max_x [D^n] \leq \theta \leq 10 \quad (30)$$

- Con la muestra conjunta, el estimador MV es $\theta = 8$, lo cual implica una distribución

$$p(\theta|D) \sim U(0, 8) \quad (31)$$

- En cambio, la metodología Bayesiana requiere una integración

$$p(x|D) = \int p(x|\theta)p(\theta|D)d\theta \quad (32)$$

Ejemplo Estimacion Bayesiana Recursiva

- La densidad solución es uniforme hasta $\theta = 8$, y tiene una cola para valores mayores indicando que la influencia del prior $p(\theta)$ no ha sido descartado por la información de la muestra de entrenamiento.
- MV estima un punto en el espacio de θ , el método bayesiano estima una densidad.
- Técnicamente, no se pueden comparar los estimadores pero si se pueden comparar las distribuciones $p(x|D)$

Identificabilidad en el enfoque Bayesiano

- Para la mayoría de las densidades $p(x|\theta)$, la sucesión de densidades $p(\theta|D)$ converge a una delta de Dirac.
- Esto implica, que con un gran número de muestras, habría un solo θ que ajuste a esos datos, por lo cual θ puede ser identificado únicamente de $p(x|D)$.
- Cuando mas de un valor de θ ajusta los datos, esto es $p(D|\theta)$ tiene el mismo valor para mas de un θ , este resulta no identificable.
- Sin embargo, $p(x|D^n)$ va a converger a $p(x|w_i)$, a pesar de la no identificabilidad de θ .
- El problema de clasificación es mas simple que el de estimación

Diferencias entre Clasificación con plug in MV y Aprendizaje Bayesiano

- Asintóticamente, en la mayoría de los casos coinciden.
- En muestra finita, sin embargo, hay diferencias a considerar
- Complejidad computacional
 - ▶ MV requiere cálculo de diferencia o búsqueda por gradiente
 - ▶ AB requiere integración multidimensional
- Interpretabilidad
 - ▶ MV da un solo valor
 - ▶ AB un promedio pesado de modelos, que a menudo son difíciles de interpretar